

Escola de Engenharia Departamento de Informática Mestrado Bioinformática

## Algoritmos para Análise de Sequências Biológicas e Laboratórios de Bioinformática

# **Trabalho Prático**

## Neisseria gonorrhoeae

**Grupo 3** *PG 28477* Diana Lemos

PG 24094 Joana Ferreira

PG 27658 Susana Gomes

Braga, Fevereiro de 2015

Grupo 3

## ÍNDICE

INTRODUÇÃO	4
Análise de literatura	5
Conhecer melhor o organismo	5
Crescimento	6
Hospedeiro e infeção	6
Fatores de virulência e patogenicidade	6
Transmissão	7
Tratamentos	8
Antibióticos	9
Bases de Dados	12
KEGG	12
UniProt	12
Scripts desenvolvidos para pesquisas na Uniprot	13
Psort	13
Grau de Revisão	14
Scripts desenvolvidos	17
Alinhamento múltiplo e Filogenia	18
Proteína: YP_207698.1	18
Proteína: YP_207697.1	20
Targets	22
Código e utilizador	24
CONCLUSÃO	25
BIBLIOGRAFIA	26
NATED CD A ELA	3.0

Indice de Figuras	
Figura 1 - zona atribuída	4
Figura 2 - Neisseria Gonorrhoeae	5
Figura 3 - Descrição do processo de transmissão da Neisseria gonorrhoeae	8
Figura 4 - Informação retirada do KEGG sobre o gene com locus tag NGO0526	12
Figura 5 - Alguma da informação retirada da UniProt sobre o gene com locus tag NGO0526	12
Figura 6 - Análise da localização celular da proteína originária do gene com locus tag NGOO	566
a partir da ferramenta Psort	13
Figura 7 - Análise Psort da proteina correspondente do gene com locus tag NGO0559	14
Figura 8 - BLASTp do gene de locus tag NGO0718, feito a partir do NCBI	15
Figura 9 - BLASTp do gene de locus tag NGO0718, feito a partir do NCBI. (cont.)	16
Figura 10 - análise das funçoes da proteina mais semelhante a partir da UniProt	16
Figura 11 - BLASTp da proteína correspondente ao gene de locust tag NGO0608	17
Figura 12 - BLASTp da proteína correspondente ao gene de locust tag NGO0608. (cont.)	17
Figura 13 - Resultados da ferramenta Blastp para a proteína YP_207698.1	18
Figura 14 – Árvore Filogenética	19
Figura 15 - Resultados do Blastp	20
Figura 16 - Árvore filogenética	20
Figura 17 - Base de dados Uniprot para a proteína Q6L0S6.1	21
Figura 18 - Base de dados Uniprot para a proteína P63969.1	21
Figura 19 – Genes essenciais e homólogos não-humanos	23
Figura 20 - Menu principal	24
Figura 21 - Menu de pesquisa de artigos	24

## INTRODUÇÃO

Este relatório foi realizado no âmbito de avaliação em grupo para as unidades curriculares de Algoritmos para Análise de Sequências Biológicas e de Laboratórios de bioinformática. Tem como objetivo a caracterização funcional de genes de uma determinada zona do genoma da bactéria *Neisseria gonorrhoeae* a partir de ferramentas bioinformáticas estudadas e aplicadas nas aulas das referidas unidades curriculares.

Para a realização deste relatório foi-nos destinada a zona do genoma da bactéria entre os genes *NGO0487* e *NGO0727*, o que corresponde a cerca de 200 genes. Assim, começou-se por fazer uma abordagem introdutória a nível da análise de artigos publicados sobre a bactéria em questão. Posteriormente, fez-se uma descrição mais detalhada de todo o processamento de informação recolhida pelas várias ferramentas bioinformáticas utilizadas.

Grupo de trabalho	Genes (locus tag)	Zona do genoma
1	NG00001 a NG00242	1 a 246000
2	NG00243 a NG00485	246001 a 468400
3	NG00487 a NG00727	468401 a 727400
4	NG00729 a NG00970	727401 a 942520
5	NG00971 a NG01212	942521 a 1162600
6	NG01213 a NG01455	1162601 a 1422700
7	NG01456 a NG01700	1422701 a 1657900
8	NG01701 a NG01940	1657901 a 1917220
9	NG01941 a NG02182	1917221 a 2153922

Figura 1 - zona atribuída

## Análise de literatura

### Conhecer melhor o organismo

A **Neisseria gonorrhoeae** ou Gonococo é uma bactéria gram negativa, do filo *Proteobacteria*, classe *Beta Proteobacteria*, ordem *Neisseriales*, família *Neisseriaceae* e género *Neisseria*. Das onze espécies de Neisseria que colonizam os seres humanos, apenas duas são patogénicas. A *Neisseria gonorrhoeae* trata-se de uma dessas bactérias patogénicas que provoca a doença designada por gonorreia.

O organismo é oval com cerca de 0,6  $\mu$ m a 1,0  $\mu$ m de diâmetro e é normalmente observado aos pares. *N. gonorrhoeae* também é optimamente cultivada entre 35°C e 36°C em *agar Thayer - Martin* e outros meios que contêm 10 % de dióxido de carbono ( o que sugere que a espécie é "capnophilic") e só oxida a glucose. Este agente patogénico também possui fímbrias (pili) que se estendem por vários micrómetros ( $\mu$ m) a partir da sua superfície e opera mecanicamente semelhante a um gancho, permitindo que as bactérias adiram às superfícies. São frágeis, morrem rapidamente no ambiente, e o único hospedeiro conhecido é o ser humano.

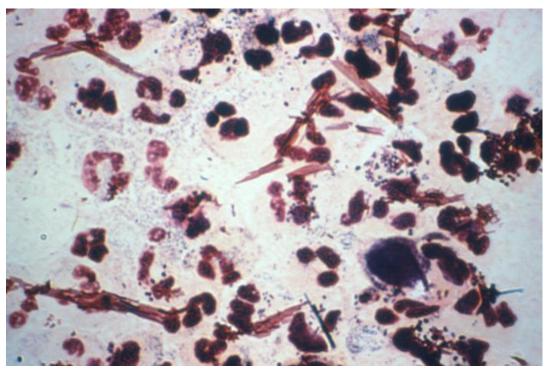


Figura 2 - Neisseria Gonorrhoeae

#### Crescimento

A *Neisseria*, em laboratório, é geralmente isolada no *Thayer-Martin agar* (agar ou VPN) que se trata de uma placa de agar que contém antibióticos (vancomicina, colistina, nistatina, e trimetoprim) e nutrientes que facilitam o crescimento de espécies de *Neisseria*, inibindo o crescimento de bactérias e fungos contaminantes.

### Hospedeiro e infeção

A *N. gonorrhoeae* tem proteínas denominadas proteínas de superfície de *Opa* que se ligam aos recetores das células. Dessa maneira é capaz de impedir uma resposta imune por parte do hospedeiro, sendo este incapaz de desenvolver uma memória imunológica o que significa que uma nova infeção seja possível no futuro.

Este organismo também pode "enganar" o sistema imunitário através de um processo chamado variação antigénica, em que a bactéria é capaz de alterar os determinantes antigénicos (locais onde os anticorpos se ligam), tais como as proteínas *Opa* e do *Tipo IV pili* que se encontram na sua superfície. As muitas permutações das proteínas da superfície tornam mais difícil o reconhecimento e a defesa da bactéria por parte das células do sistema imunológico.

### Fatores de virulência e patogenicidade

Existem quatro tipos diferentes de resistência desta espécie, nomeadamente T1, T2, T3, T4 que são classificadas pelas suas **fímbrias**. As suas membranas externas são compostas por proteínas, fosfolípidos, e lipopolissacarídeos (LPS). Os lipopolissacáridos do organismo *N. gonorrhoeae* são diferentes daqueles encontrados em bactérias entéricas, porque estes são oligossacarídeos basais altamente ramificados e não possuem as subunidades de repetição do O-antigénio. Assim, o LPS da *Neisseria* é referido como **lipo-oligossacárido** (LOS). Durante o seu crescimento, liberta os fragmentos da membrana externa conhecidos como "bolhas", sendo estas vesículas que contêm o LOS, que se pensa ter um papel na patogénese durante o seu processo de infecção.

As paredes celulares da *N. gonorrhoeae* contêm proteínas que residem na superfície da membrana externa ou atravessam a membrana exterior (proteínas integrais). As bactérias utilizam estas proteínas da membrana externa e as suas fímbrias para invadir o hospedeiro.

Primeiro, estas bactérias utilizam as suas fímbrias para se fixarem nas células epiteliais não ciliadas da trompa de Falópio, e depois entram nas células epiteliais por endocitose. Durante todo o processo de endocitose, a membrana da célula puxa e aperta um vacúolo ligado à membrana que tem as bactérias no interior da mesma. Este vacúolo desloca-se para a base da célula de modo a que as bactérias possam

ser libertadas para o tecido subepitelial e dessa maneira pode causar, com sucesso, uma infeção no hospedeiro.

Uma vez dentro do hospedeiro, a bactéria produz dois tipos de proteases **IgA** extracelulares que possuem a capacidade de clivar diferentes áreas da região dobradiça das moléculas de cadeia pesada da imunoglobulina humana. O dano celular é causado pela libertação de LOS e do peptidoglicano, que ativam a via alternativa do complemento e a produção do fator de necrose tumoral.

A virulência pode ficar comprometida caso o microrganismo sofra alterações estruturais de superfície.[7]

#### Transmissão

A Neisseria gonorrhoeae é adquirida através do contacto sexual e estabelece a infeção no trato urogenital, interagindo com as células epiteliais não ciliadas, resultando na invasão celular. Apesar dos diferentes mecanismos moleculares envolvidos durante o estabelecimento da bactéria nas superfícies mucosas masculinas e femininas, a infeção leva muitas vezes à inflamação e ao afluxo de leucócitos polimorfonucleares (PMN). No entanto, a infeção do trato genital inferior feminino é geralmente assintomática. As *N. gonorrhoeae* tragadas por PMN são secretadas no exsudato rico em PMN. Tanto o fator de necrose tumoral (TNF) de fagócitos como os produtos gonocócicos, tais como o peptidoglicano e lipopolissacarídeo (LPS), também causam danos tóxicos às células epiteliais ciliadas das superfícies mucosas. ECM é a matriz extracelular [2].

A imagem a seguir apresentada, representa a descrição do processo de transmissão da *Neisseria gonorrhoeae*:

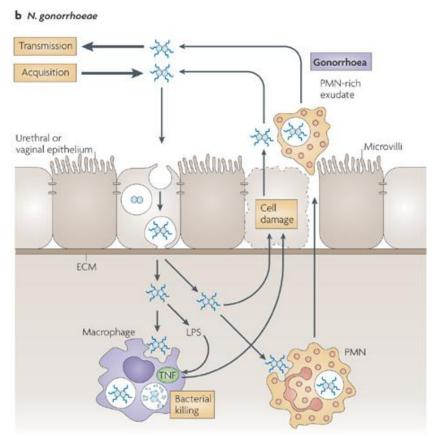


Figura 3 - Descrição do processo de transmissão da Neisseria gonorrhoeae.

Aproximadamente 45% das mulheres infetadas apresentam uma infeção gonococcal ascendente e subsequente PID (*Pelvic Inflammatory Disease*). A PID é frequentemente a causa de infertilidade e gravidez etópica devido ao bloqueio permanente das trompas de Falópio. A infeção nos homens leva a uretrite, epididimite, e prostatite [6].

#### **Tratamentos**

Se a *N. gonorrhoeae* é resistente aos antibióticos da família da penicilina, então recorre-se muitas vezes aos antibióticos ceftriaxone (cefalosporina de terceira geração). Estes, assim como outros beta lactâmicos interrompem a síntese de peptidoglicano (confere rigidez à parede celular das bactérias).

Dentro da *N. gonorrhoeae* existem genes que conferem resistência a cada um dos antibióticos utilizados para curar a gonorreia, mas até agora não co-existem dentro de um único *gonococcus*. No entanto, devido à alta afinidade para a transferência horizontal de genes da *N. gonorrhoeae*, a gonorreia com resistência a antibióticos é vista como uma ameaça emergente da saúde pública.

Apesar das descobertas que indicam que as fluoroquinolonas têm taxas de cura semelhantes às da ceftriaxona, a *N. gonorrhoeae* tornou-se cada vez mais resistente às *fluoroquinolonas* em algumas áreas geográficas. Portanto, o CDC

(Centro de Controle e Prevenção de Doenças) não aconselha o uso de fluoroquinolones para tratar a infecção em pacientes que vivem ou possam ter adquirido a infecção na Ásia, nas ilhas do Pacífico e Califórnia. O CDC observou recentemente um aumento substancial de *N. gonorrhoeae* resistentes a fluoroquinolonas em homens que têm relações sexuais com outros homens e já não recomenda fluoroquinolonas como tratamento de primeira linha nestes pacientes. Na Inglaterra, no País de Gales e no Canadá também relataram casos de *N. gonorrhoeae* resistente a fluoroquinolonas.[9]

#### **Antibióticos**

Os antibióticos são fármacos utilizados para tratar infecções bacterianas, matando ou inibindo o crescimento dos microrganismos. São capazes de inibir em baixas doses, processos vitais das bactérias. (KESTER et al, 2008). O antibiótico age sobre o mecanismo de construção da parede celular da bactéria, deixando as células humanas intactas.

Uma compreensão abrangente da prevalência da diminuíção da sensibilidade às cefalosporinas de amplo espectro (ESCds) e os tipos de sequência (ST) de deformações de *N. gonorrhoeae* em circulação nas populações de pacientes, podem ajudar a orientar as decisões chave para o planeamento da gestão da *N. gonorrhoeae*.

Vários estudos têm mostrado que a acumulação de mutações nos genes cromossómicos pode conduzir ao fenótipo de ESCds. Os genes estudados incluem penA, que codifica a proteína de ligação à penicilina 2 (PBP 2); porB1, que codifica uma proteína de membrana externa do canal relacionada com a entrada dos antibióticos; ponA, que codifica PBP 1; pilQ, que codifica a secretina PilQ da membrana externa; e mtrR, um repressor da bomba de efluxo MTRC - MtrD - MtrE. Polimorfismos no alelo penA foram significativamente associados com as ESCds na N. gonorrhoeae. PBP 2 é uma enzima ligada à membrana envolvida na síntese da parede celular e em mutações em posições diferentes podem resultar em diferentes graus de aumento de MICs. Vários estudos têm sugerido que as estirpes resistentes são em grande parte clonadas e contêm padrões em mosaico de PBP 2 específicos, como o tipo XXXIV. A sequência do tipo 1407, com base nos genes por e tbpB, também tem sido associada com as ESCds [1].

A infecção da *Neisseria gonorrhoeae* é uma das causas mais comuns de uretrite na Polónia. A resistência das bactérias a uma ampla gama de antibióticos, incluindo a *ciprofloxacina*, torna mais difícil o tratamento da gonorreia. O mecanismo de ação da *ciprofloxacina* depende da inactivação bacteriana da *topoisomerase II* (girase) e da *topoisomerase IV*. A resistência à *ciprofloxacina* que ocorre na *Neisseria gonorrhoeae* deve-se principalmente a mutações em genes bacterianos *gyrA* (codificação topoisomerase II) e/ou *parC* (codificação topoisomerase IV). O nível de resistência elevado é um efeito da combinação de três ou quatro mutações. Outro mecanismo menos importante da resistência à *ciprofloxacina*, que pode coexistir com as mutações nos genes *gyrA* e *parC* está relacionado ao excesso de produção de bombas de proteínas membranares [2].

A Neisseria gonorrhoeae pode desenvolver rapidamente resistência aos agentes antimicrobianos. Ao longo dos últimos anos, a diminuição da sensibilidade

gonocócica às cefalosporinas de terceira geração, especialmente à cefixima, surgiu em todo o mundo. Portanto, as orientações internacionais atuais recomendam o tratamento duplo para a gonorreia, com a ceftriaxona mais a azitromicina ou a doxiciclina.

Foram testados um total de 320 isolados. Entre 1990 e 2006, todas as amostras testadas foram suscetíveis às dois cefalosporinas . Subsequentemente, a prevalência de MICs elevadas para a cefixima aumentou para 10,4% (2007/2008), 11,5% (2009/2010), e 11,4% (2011/2012); e para a ceftriaxona aumentou 2,4% (2007/2008), 4,7% (2009/2010), e 0% (2011/2012), respectivamente. A prevalência da resistência à ciprofloxacina (72,7%) e à penicilina (22,7%) foi elevada em 2011/2012 .

A diminuição da susceptibilidade da *N. gonorrhoeae* às cefalosporinas de terceira geração na Suíça apoia as recomendações de tratamento com a ceftriaxona mais a azitromicina ou a doxiciclina. Os profissionais de saúde precisam estar cientes das possíveis falhas no tratamento com cefalosporinas. A supervisão contínua da resistência antimicrobiana gonocócica é essencial [3].

A incidência estimada de novos casos de gonorreia está a aumentar e o perfil de resistência antimicrobiana da *N. gonorrhoeae* está a piorar. A recente e mais significativa descoberta foi o surgimento da *N. gonorrhoeae XDR* (extensively drugresistant) caracterizada por concentrações inibitórias mínimas muito altas de ceftriaxona. Uma mudança nacional de cefixima para ceftriaxona em altas doses, como tratamento antigonococcal de primeira linha na Inglaterra e no País de Gales, bem como partes do Japão, foi acompanhada por uma redução na prevalência de gonococci resistente a ESC oral. A azitromicina administrada em conjunto com gentamicina ou gemifloxacina tem-se mostrado ser um tratamento antigonococcal alternativo eficaz. Tanto *ertapenem* como *solithromycin* têm boa atividade *in vitro* contra estirpes de *N. gonorrhoeae* resistentes a ESC [4].

## Descrição do trabalho elaborado

O primeiro passo foi criar um *script* que acede ao ncbi e guarda num ficheiro *genbank* a zona do genoma correspondente. De maneira a verificar se a informação retirada é realmente a pretendida, foi feito um *script* que compara a informação dos genes presentes na zona e os genes anotados numa tabela do ncbi. É de notar que devido a diferenção nas localizações dos genes, a validação da tabela não é a pretendida. Por essa razão esse *script* não está a ser usado.

Sendo o objetivo deste trabalho a caracterização dos genes da zona do genoma atribuída, foi gerada uma tabela automaticamente, por meio de scripts em biopython, onde apresenta locus tag de cada gene, o seu Gene ID, a sua localização no genoma, acession number e proteínas resultantes, para cada gene na base de dados da NCBI.

Para gerar essa tabela foram feitos scripts em *python* para extrair a informação das *features* dos genes tipo *CDS*.

Posteriormente completou-se essa mesma tabela com a seguinte informação: grau de revisão, número de aminoácidos da proteína resultante de cada gene, EC Number, KEGG Orthologs, KEGG pathways, Celular Location, Função, GeneOntology (GO), descrição e alguns comentários pertinentes. Para a recolha dessa informação recorreu-se a bases de dados como KEGG, Psort e Uniprot.

#### Bases de Dados

Para completar a tabela dos genes com informação sobre os mesmos foram feitas pesquisas em várias bases de dados. Essa pesquisa foi maioritariamente manual.

#### KEGG

Nesta base de dados a partir do *locus tag* de cada gene retirou-se informação referente ao tamanho da proteína produzida, *EC Number, KEGG Orthologs* e *KEGG pathways*.

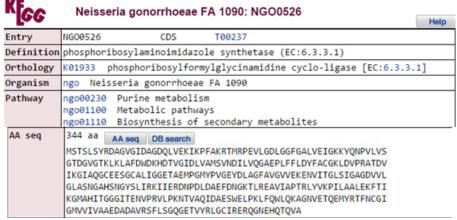


Figura 4 - Informação retirada do KEGG sobre o gene com locus tag NGO0526.

#### UniProt

Nesta base de dados retirou-se a restante informação para completar a tabela, ou seja, o grau de revisão, Celular Location, Função, *GeneOntology (GO)* e descrição. Os comentários foram também baseados na informação retirada a partir desta base de dados.



Figura 5 - Alguma da informação retirada da UniProt sobre o gene com locus tag NGO0526.

Scripts desenvolvidos para pesquisas na Uniprot

Com a ferramenta *Biopython* foi desenvolvido um script onde é possível obter os IDs do *Uniprot* para a pesquisa das proteínas. Neste código, o utilizador insere o valor *acession* (presente na tabela de genes) e obtém o respetivo valor ID do uniprot, com esse valor é feita a pesquisa para o restante código.

Também é possível obter a informação de determinada proteína num ficheiro e também qual a revisão da mesma, ou seja, se é *reviewed* ou *unreviewed*.

#### **Psort**

Por vezes a localização celular não é fornecida pela *UniProt*, assim é necessário recorrer a outros meios.

Para determinação da localização celular da proteína, produzida a partir de um determinado gene de interesse, recorreu-se à *Psort*. Esta ferramenta recebe informação de uma sequência proteíca e a sua *táxon* de origem (se provém de bactérias gram positivas ou negativas) e informa qual a probabilidade de determinada proteína estar localizada em cada local com alguma informação adicional.



Submit Sequences | Documentation | Resources | Contact | Updates

#### PSORTb Results (Click here for an explanation of the output formats)

```
SeqID: sp|Q5F938|SYP_NEIG1 Proline--tRNA ligase OS=Neisseria gonorrhoeae (strain ATCC 780825 / FA 1898) GN=proS PE=3 SV=1
  Analysis Report:
    EvtoSVM-
                         Cytoplasmic
                                                              [No details
    ECSVM-
                                                             [No details]
                         Unknown
                                                             [No internal helices found]
[No motifs found]
     Madients.
                         Unknown
    Motif-
                         Unknown
                                                             [No motifs found]
     CMPMotif-
    OMSVM-
                         Unknown
                                                             [No details]
    PPSVM-
                         Unknown
                                                             [No details]
                                                             [matched <u>PSS8862</u> AA_TRNA_LIGASE_II Profile - Cytoplasmic ]
[matched <u>34399088</u>: Prolyl-tRNA synthetase]
[No matches against database]
     Profile-
                         Cytoplasmic
     SCL-BLAST-
                         Cytoplasmic
     SCL-BLASTe-
                         Unknown
    Signal-
                         Unknown
                                                             [No signal peptide detected]
  Localization Scores:
     Cytoplasmic
    CytoplasmicMembrane
                               0.00
     Periplasmic
                                0.00
    Extracellular
                               0.00
  Final Prediction:
```

Figura 6 - Análise da localização celular da proteína originária do gene com locus tag NGO0566 a partir da ferramenta Psort.

No caso da imagem anterior, conclui-se rapidamente que a proteina se encontra no citoplasma da célula visto que o *localization score* é maximo nesse local.

Contudo, por vezes, nem mesmo o *Psort* disponibiliza uma informação exata sobre a localização de determinadas proteínas, como é o caso da proteína do gene *NGO0559*, como mostra a imagem seguinte. Nestes casos teve de se considerar localização desconhecida.



Figura 7 - Análise Psort da proteina correspondente do gene com locus tag NGO0559.

#### Grau de Revisão

O grau de revisão de cada gene foi um fator crucial para o preenchimento desta tabela, uma vez que quando um gene é *Unreviewed* é necessário procederse a uma análise mais cuidada do mesmo. Nestes casos o algoritmo *BLAST* é essencial.

Neste projeto, dos 211 genes/proteínas a analisar, apenas 34 são reviewed (segundo a base de dados *Uniprot*).

#### **BLAST**

O algoritmo *BLAST* (*Basic Local Alignment Search Tool*) permite comparar informações de sequências biológicas (proteicas ou de DNA), ou seja, uma sequência fornecida é comparada com uma biblioteca de sequências de forma a identificar quais as que mais apresentam maior grau de semelhança à sequência de interesse. Esse grau de semelhança determina-se por análise de alguns valores, como *e-values* e a *query cover*.

Assim, a partir do momento que um gene é *Unreviewed* toda a restante informação, que ainda é desconhecida, será provavelmente similar a um outro gene com grau de semelhança bastante elevado relativamente ao gene de interesse.

No caso da figura seguinte realizou-se um *BLASTp*, ou seja, realizou-se um *BLAST* usando a sequência proteíca do gene de interesse. Analisando os resultados pode-se verificar que os dois primeiros *hits* são os que apresentam melhor *query cover* com a sequência submetida. Embora o segundo *hit* tenha maior área de semelhança com a proteína de interesse considerou-se o primeiro *hit* como sendo o de maior grau se semelhança, uma vez que apresenta melhor *e-value* do que o segundo.

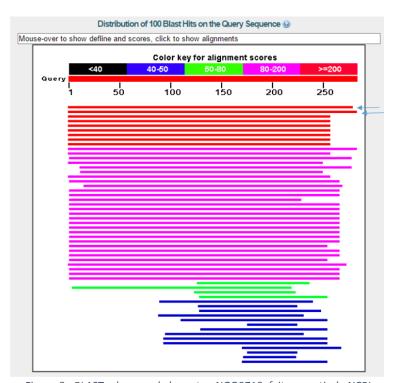


Figura 8 - BLASTp do gene de locus tag NGO0718, feito a partir do NCBI.

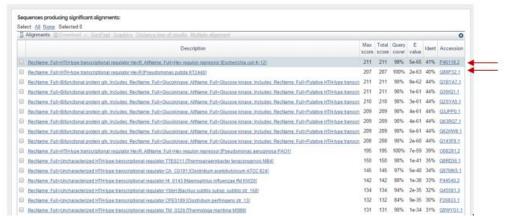


Figura 9 - BLASTp do gene de locus tag NGO0718, feito a partir do NCBI. (cont.)

Conhecendo a proteína que mais se assemelha à proteína de interesse efectua-se uma pesquisa a partir da *UniProt* para então descobrir a sua possível função. Neste caso considerou-se que tem função de Transcription regulation.



Figura 10 - análise das funçoes da proteina mais semelhante a partir da UniProt.

Contudo, nem sempre se podem fazer associações deste tipo, uma vez que por vezes não há organismos com graus de semelhança suficientemente elevados para que sejam considerados homólogos.

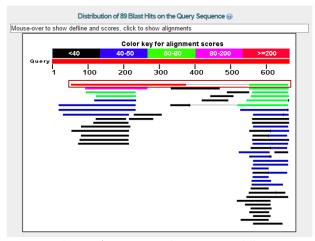


Figura 11 - BLASTp da proteína correspondente ao gene de locust tag NGO0608.

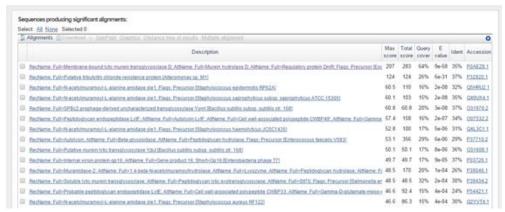


Figura 12 - BLASTp da proteína correspondente ao gene de locust tag NGO0608. (cont.)

Na imagem anterior consegue-se verificar que na zona rodeada a vermelho a zona de semelhança com outras proteinas é muito má, não havendo nenhuma com uma zona *query cover* aceitável. Verificando a descrição consegue-se averiguar que embora o primeiro *hit* apresente baixo valor de *query cover*, apresenta um *e-value* muito aceitável.

Em situações destas, é aconselhável usar outro tipo de estratégias para que consigamos obter dados mais exatos, como é o caso da análise filogenética de sequências.

#### Scripts desenvolvidos

Foi desenvolvido um *script* em *python* que faz o *blastp* e devolve um ficheiro com os resultados. O utilizador insere o valor do *locus tag* correspondente ao gene que pretende fazer o blastp.

Também é feita a análise desse *blast*, nessa análise são apresentados todos os *hits*, os seus *evalues* e as suas posições.

## Alinhamento múltiplo e Filogenia

Ferramentas deste tipo são bastante úteis para o estudo mais aprofundado de genes/proteínas de interesse. Foi necessário esta análise quer para reforçar as anotações feitas, quer para conduzir a hipóteses que ainda não tenham sido determinadas por outros métodos.

De maneira a estudar melhor uma proteína selecionou-se a sequência da proteína em estudo e um conjunto de sequências homólogas de organismo selecionados (resultantes do *Blastp*). Primeiramente realizou-se o alinhamento múltiplo e depois determinou-se a árvore filogenética correspondente.

Foi desenvolvido um script para determinar o alinhamento múltiplo de sequências e a árvore filogenética. Para o alinhamento múltiplo é passado como argumento um ficheiro com extensão .phy resultante do Clustal Omega. Para determinar a árvore, é passado como argumento um ficheiro .dnd resultante da ferramenta ClustalW2.

Proteína: YP\_207698.1

Localização: Membrana plasmática

Pela anotação do uniprot é uma proteína unreviewed e localiza-se na membrana citoplasmática. Como a sua função é desconhecida fez-se a sua análise filogenética.

Numa primeira etapa fez-se um *Blast* de proteínas obtendo-se o seguinte resultado:

Sequences producing significant alignments:						
Select: All None Selected:0						
Alignments Download GenPept Graphics Distance tree of results Multiple alignment						
Description			Query cover		Ident	Access
RecName: Full=Uncharacterized protein Ht 1376 [Haemophilus influenzae Rd KW20]	300	300	98%	1e-99	56%	P44170
RecName: Full=30S ribosomal protein S8 [Desulfurococcus kamchalkensis 1221n]	34.7	34.7	21%	0.31	30%	B8D5V5
RecName: Full=Polycystic kidney disease protein 1-like 1; AltName: Full=PC1-like 1 protein; AltName: Full=Polycystin-1L1 [Homo sapiens]	32.3	32.3	66%	5.6	25%	Q8TDX9

Figura 13 - Resultados da ferramenta Blastp para a proteína YP\_207698.1.

Como se pode verificar apenas uma das sequências obtidas como resultado tem valores *Evalue*, *Ident* e *Query cover* satisfatórios. Com estes resultados podese ver que há bastantes semelhanças entre a proteína em estudo e o primeiro resultado do *blastp* (*P44170.1*), que se encontra destacado a vermelho.

Para verificar e testar a similaridade entre as sequências, realizou-se um alinhamento duplo com a sequência em estudo e todas as sequências resultantes do blast. O esperado é que as duas últimas sequências da figura ... sejam distantes das restantes.

Para os alinhamentos duplos utilizou-se o código desenvolvido pelo grupo, em que foi passado como argumento o ficheiro .phy

Por fim desenvolveu-se a árvore filogenética, utilizando a ferramente Clustalw2 e para gerar a árvore utilizou-se o código desenvolvido pelo grupo. O resultado final foi o sequinte:

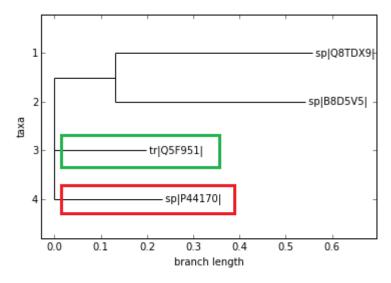


Figura 14 – Árvore Filogenética

Pode-se verificar que a proteína em estudo (verde) e a proteína obtida como primeiro resultado do *blast* (vermelho), são mais próximas do que as restantes, o que era de esperar. No entanto o seu grau de semelhança não é assim tão elevado.

Fazendo uma pesquisa no Uniprot pela proteína *P44170*, pode-se ver que se trata de uma proteína *reviewed*, sendo o seu nome *Uncharacterized protein HI\_1376* e está relacionada com a membrana plasmática. A proteína que em estudo tem uma localização celular na membrana plasmática, o que comprova que ambas têm algum grau de similaridade.

Esta análise veio intensificar a hipótese anterior: a proteína em estudo, YP\_207698.1 tem uma localização celular na membrana plasmática, sendo uma potencial candidata à ação dos antibióticos.

Proteína: YP\_207697.1

Localização: Membrana plasmática

A mesma análise foi feita para a proteína *YP\_207697.1*. Após o *Blastp* obteve-se os seguintes resultados:



Figura 15 - Resultados do Blastp

Para a análise da filogenia utilizou-se as primeiras sete sequências homólogas. O primeiro passo foi fazer o alinhamento múltiplo das sequências e depois determinar a árvore filogenética. Para gerar a árvore filogenética utilizou-se a ferramenta *ClustalW2* e o código desenvolvido pelo grupo. Este código recebe como argumento o ficheiro resultante do *ClustalW2* (extensão .dnd) e cria a respetiva árvore filogenética. O resultado foi o seguinte:

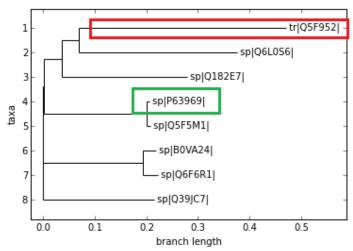


Figura 16 - Árvore filogenética

Pode-se verificar que a sequência em estudo (vermelho) é mais semelhante com a Q6L0S6 e não com a primeira obtida nos resultados do *Blastp* (verde).

Pesquisando na base de dados Uniprot pela *Q6L0S6.1* pode-se ver que é uma proteína reviewed com score 3/5, pertence ao organismo *Picrophilus torridus*, é uma proteína Chaperone e tem função de dna replication e stress response.



Figura 17 - Base de dados Uniprot para a proteína Q6L0S6.1.

Analisando a proteína *P63969.1* na base de dados *Uniprot*, pode-se verificar que pertence ao organismo *Neisseria meningitidis serogroup B*, é reviewed com score 3/5, é uma proteína Chaperone e tem as mesmas funções que a proteína anterior, como é apresentado na figura seguinte:

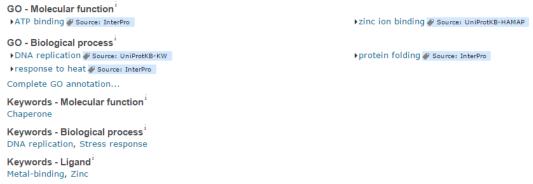


Figura 18 - Base de dados Uniprot para a proteína P63969.1.

Ambas as proteínas apresentam muita similaridade com a proteína em estudo e ambas têm a mesma função. Com isto podemos concluir que uma possível função para a proteína a ser estudada, YP\_207697.1, está relacionada com dna replication e stress response.

Em relação à localização celular utilizou-se a ferramenta *PSort*. Para a proteína a ser estudada após a análise da provável localização obteve-se a membrana plasmática. O mesmo processo foi utilizado para a *P63969.1* e *Q6L0S6.1*. Para estas duas proteínas a localização mais provável obtida foi no citoplasma e não na membrana plasmática, com uma probabilidade de 9.97.

### **Targets**

A transmissão e a infeção gonocócica é um problema global de saúde e estão ainda a ser desenvolvidos medicamentos e vacinas eficazes. Segundo o estudo "Candidate Drug and Vaccine Targets from Various Pathways in Neisseria gonorrhoeae", foram identificados seis enzyme drug targets possíveis e três vaccine targets a partir de várias vias metabólicas que se prevê que venham a ser essenciais para o agente patogénico.

Num estudo de um artigo, foram identificados 537 genes que compreendem 26 % do número total de sequências de codificação de proteína no genoma da *N. gonorrhoeae* estirpe 1090 FA a serem essenciais e podem ser agrupadas em 21 classes de acordo com classificação funcional COG (Fig.\_). A identificação de um maior número de genes essenciais neste estudo em relação a um estudo anterior, deve-se ao aumento do número de genes essenciais para a versão atual do DEG (versão 5.2). Os genes essenciais identificados pensa-se serem de vários grupos funcionais. Os genes que estão envolvidos em maquinaria de tradução constituem o maior grupo (91 genes) e o grupo de processamento do RNA representa o menor número (gene 1). A razão entre o número de genes essenciais para os homólogos não humanos dentro um grupo funcional foi considerada alta (91 a 14) na classe de maquinaria de tradução de genes, sendo igual (4 para 4) nos genes no grupo de sinal transdutor (Fig.\_).

Considerando as vias metabólicas comuns dos hospedeiros patogénicos, estão presentes 76 enzimas metabólicas que apenas são encontradas em N. gonorrhoeae. Entre estas enzimas, 67 são citoplasmáticas (potenciais *drug targets*) e 9 pensa-se estarem localizadas na membrana. No entanto, uma destas é uma enzima de superfície (lipoproteína de competência: NGO0277). Das vias metabólicas comuns dos hospedeiros patogénicos, também são identificados 9 integrais de membrana e um transportador gonocócico essencial homólogo não-humano localizado na parede celular. Nove enzimas membranares e dez transportadores membranares pensa-se serem potenciais candidatos a *vaccine targets* de vias metabólicas comuns onde a proteína permease C de transporte de sulfato (*cysW*) pode ser um dos melhores *targets*. Em comparação com a lista de vias metabólicas humanas presentes na base de dados KEGG, são 10 os caminhos que se verificam ser únicos na *N. gonorrhoeae*.

A membrana externa *lipo-oligossacarídeos* da *N. gonorrhoeae* confere a virulência bacteriana. Assim, tendo a via biossintética lipo-polissacárideo como *target* pode ser eficaz para evitar a infeção. As proteases *IgA1*, *Opa*, *lipo-oligossacáridos*, proteína-I *lactoferrina* (Lbpl, Lbp2), e 2C7 *epitopo oligosacárido* (OS) são referidos como candidatos a vacinas. De entre as 8 proteínas da via biossintética lipo-polissacarídea identificadas, a *UDP-3-O-acyl N-acetylglucosamine deacetylase* (*IpxC/Enva*) e o *lipopolysaccharide heptosyltransferase-I* (rfaC) também se pensam estrar envolvidos no metabolismo amino ácido (arginina, prolina, histidina) e nas vias *glycan structures-biosynthesis-2*. Portanto, tendo em conta que *envA* e *rfaC* estão envolvidos em duas vias metabólicas, estes podem ser considerados melhores *targets*.

O sistema bacteriano de duas componentes é crucial para o crescimento e sobrevivência em condições extremas. São quatro as enzimas essenciais e duas as proteínas reguladoras consideradas potenciais *drug targets* nesta via. Entre estas enzimas identificadas, *tryptophan synthase subunit A (trpA)*, *indole-3-glycerol-phosphate synthase (trpC)*, e *anthranilate phosphoribosyltransferase (trpD)* também são considerados componentes principais na fenilalanina, na tirosina, e nas vias de biossíntese do triptofano. Portanto, tendo como *targets* estas três enzimas, podem ser interrompidas as vias essenciais para a sobrevivência e virulência da *N. gonorrhoeae* e, portanto, esta pode ser uma potencial estratégia de tratamento antibacteriano [5].

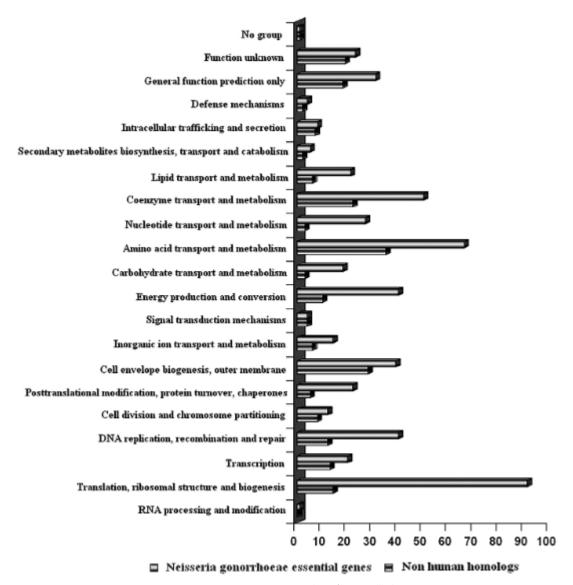


Figura 19 – Genes essenciais e homólogos não-humanos

## Código e utilizador

De maneira a haver uma interação com o utilizador, foi desenvolvido um menu em que são disponibilizadas várias opções, tais como: obter ficheiro correspondente à zona do genoma, ver as anotações desse ficheiro, obter a tabela inicial com todos os genes, fazer blast, pesquisar no uniprot, entre outras.

Figura 20 - Menu principal.

Outro menu foi criado, neste menu é possível fazer alguma pesquisa de artigos. O utilizador pode pesquisar artigos pelo título, autor e se assim o preferir fazer a pesquisa de todos os artigos sobre o organismo em estudo. A pesquisa foi feita no *Pubmed*.

```
+++++++ PESQUISA DE ARTIGOS ++++++++

1 - Todos artigos da Neisseria gonorrhoeae
2 - Procurar artigo por título
3 - Procurar artigo por autor
4 - Procurar abstract
5 - Todos artigos sobre resistência
0 - Exit
```

Insira a opcao desejada:

Figura 21 - Menu de pesquisa de artigos.

## CONCLUSÃO

Com a realização deste trabalho conseguimos fazer um estudo mais detalhado da zona do genoma que nos foi destinada. Assim, a nível de literatura conseguimos comprovar que a melhor forma de inativar a patogenicidade desta bactéria será tendo como alvo a sua membrana citoplasmática. Sabendo isso todo o trabalho se direcionou na pesquisa, através de bases de dados e ferramentas bioinformáticas, para se fazer localizar todos os genes de interesse, ou seja, que estejam relacionados com funções da membrana citoplasmática. Essas bases de dados (como o caso do NCBI, UniProt, KEGG, BRENDA, etc.) fornecem a mais variada informação relativo a genes e proteínas estudadas até ao momento. Já as ferramentas ferramentas bioinformáticas que nos permitem trabalhar com a informação fornecida por essas bases de dados. Ferramentas essas (como o caso de *BLAST*, arvores filogenéticas, *Psort*, etc.) permitem fazer procuras mais detalhadas de determinados genes ou então fazer comparações entre sequencias genómicas ou protéicas de interesse e descobrir outras sequências semelhantes já estudadas, entre outras funções.

Para este relatório foram utlizadas ferramentas que consistem em *scripts* realizados pelo grupo para recolha de informação que foram, posteriormente, completados a partir de outras ferramentas fornecidas *online*.

Para tal, focou-se na realização de uma tabela com a listagem de genes e das suas principais anotações recolhidas a partir das referidas ferramentas, dando especial atenção às anotações referentes às suas funções e a sua localização celular para entao se localizar todos os genes de interesse.

Este tipo de análise verificou-se fundamental para quando se pretende conhecer o funcionamento de um organismo e as melhores formas de o melhorar ou então de combater a sua patogenicidade, dependendo do objetivo pretendido. Contudo, o melhoramento da informação fornecida só será possível se houver uma actualização constante da informação fornecida online.

#### **BIBLIOGRAFIA**

- [1] Kanti Pabbaraju, Sallene Wong, Joanna J. Song, Ameeta E. Singh, Ron Read, and Steven J. Drewsa, Utility of Specimens Positive for Neisseria gonorrhoeae by the Aptima Combo 2 Assay for Assessment of Strain Diversity and Antibiotic Resistance, J Clin Microbiol. 2013 Dec; 51(12): 4156–4160.
- [2] Młynarczyk-Bonikowska B, Kujawa M, Młynarczyk G, Malejczyk M, Majewski S, [Resistance to ciprofloxacin of Neisseria gonorrhoeae strains isolated in Poland in 2012-2013], Med Dosw Mikrobiol. 2014;66(2):99-104.
- [3] Kovari H, de Melo Oliveira MD, Hauser P, Läuchli S, Meyer J, Weber R, Zbinden R, Decreased susceptibility of Neisseria gonorrhoeae isolates from Switzerland to Cefixime and Ceftriaxone: antimicrobial susceptibility data from 1990 and 2000 to 2012, BMC Infect Dis. 2013 Dec 26;13:603. doi: 10.1186/1471-2334-13-603.
- [4] Lewis DA, Global resistance of Neisseria gonorrhoeae: when theory becomes reality, Curr Opin Infect Dis. 2014 Feb;27(1):62-7. doi: 10.1097/QCO.00000000000000055.
- [5] D. Barh and A. Kumar, Candidate Drug and Vaccine Targets from Various Pathways in Neisseria gonorrhoeae, In Silico Biology 9 (2009) 225–231, DOI 10.3233/ISB-2009-0399, IOS Press.
- [6] D. Barh and A. Kumar, Candidate Drug and Vaccine Targets from Various Pathways in Neisseria gonorrhoeae, In Silico Biology 9 (2009) 225–231, DOI 10.3233/ISB-2009-0399, IOS Press.

#### **WEBGRAFIA**

- [7] http://www.ppdictionary.com/bacteria/gnbac/gonorrhoeae.htm
- [8] http://www.nature.com/nrmicro/journal/v7/n4/fig\_tab/nrmicro2097\_F1.html
- [9] http://www.aafp.org/afp/2006/0515/p1779.html